

信用卡申请评分模型的构建与多模型对比分析

摘 要

本文针对信用卡申请评分问题，构建了一套基于 WOE-IV 变量筛选与逻辑回归评分卡的完整信用风险评估模型。研究整合三个异构数据源：438,557 条申请记录（18 字段）、15,277,108 条月度征信记录（3 字段）和 629,487 条信用局外部评分（2 字段），经三阶段数据清洗与多维特征工程后形成 90,067 条有效建模样本（27 维特征空间）。

在数据预处理阶段，本文提出了“基于内容去重+分类填充+时序特征提取”的三阶段清洗框架。发现 79.5% 的记录存在跨渠道内容重复，经保守去重后保留 90,085 条独立样本。从 1,527 万条征信时序数据中提取了覆盖频率、严重度、最新状态和时间趋势四个维度的 8 维行为特征，并整合信用局外部评分（200-979 分）作为独立信用参考变量。

在变量筛选阶段，采用等频 WOE 分箱与信息价值评估方法对 25 个候选变量进行预测力排序，最终筛选出 8 个有效预测变量，并主动识别剔除了 2 个存在目标泄露风险的变量。

在评分卡建模阶段，建立了基于 WOE 转换的逻辑回归评分卡模型。测试集 AUC 达 0.7655，KS 统计量为 0.3837，Gini 系数为 0.5310，5 折交叉验证 AUC 为 0.7679 ± 0.0059 。评分卡（PDO=20，“Base”=600，Odds=1:50）输出评分范围 655-915 分，各组坏客户率严格单调递减：最低组 9.16% 至最高组 0.11%。

在模型对比阶段，逻辑回归在 AUC 和 KS 上均优于决策树、随机森林和 AdaBoost。三维度灵敏度分析验证了模型的稳健性（AUC 波动小于 0.009）。

关键词： 信用评分卡；WOE 分箱；信息价值；逻辑回归；KS 统计量；模型对比

问题重述与分析

问题背景及重述

信用卡作为消费金融的核心产品，其申请审批环节的风险评估直接关系到金融机构的资产质量和盈利能力。传统的审批依赖人工审核，存在效率低下、标准不一致等问题。信用评分卡（Credit Scorecard）通过量化分析输出标准化评分，帮助机构做出客观一致的信贷决策[1][2]。

问题分析

本题的核心挑战在于三个层面：第一，三源数据整合——申请表、征信记录和信用局评分来自不同的信息系统，ID 匹配存在不完整（约 13,229 名申请人无征信记录），数据粒度和时间跨度不一致，需要设计统一的融合框架；第二，极端类别不平衡——坏客户仅占 2.37%，这意味着一个永远预测“好客户”的朴素模型准确率高达 97.63%，使得常规分类指标失效，必须采用 AUC、KS 等不受分布影响的评估指标[7][8]；第三，时序信息压缩——60 个月的征信记录包含行为演变模式，但逻辑回归评分卡框架要求静态特征输入，如何从 25MB 的时序数据中提取有预测力的统计摘要而不丢失关键动态信号，是特征工程的核心难点。

本题要求完成四项任务：（1）数据清洗与预处理，包括去重、缺失值处理、异常值检测与变量转换；（2）定义目标变量 Y，使用 IV 方法筛选有效变量；（3）建立基于 WOE 转换的逻辑回归评分卡模型；（4）使用决策树、随机森林和 AdaBoost 进行多模型对比分析。

分析思路与技术路线

本文遵循信用评分卡建模的行业标准流程，设计了一条完整闭环技术路线，分为数据层（三源数据整合与清洗）、特征层（WOE 分箱与 IV 筛选）、模型层（评分卡构建与多模型对比）和验证层（灵敏度分析）四个层次。




图 1-1 技术路线与数据质量概览

图 1-1 展示了本文的四层分析架构。左侧面板呈现了数据缺失和收入分布，右侧为各阶段的关键方法。该框架体现了“数据驱动、模型严谨、验证充分”的建模理念，各层次之间环环相扣——上层的建模决策（如 WOE 分箱、IV 阈值选择）受到下层数据质量分析结果的约束，保证了建模过程的系统性和可复现性。

本文的核心工作与创新如下（融入正文表述，不单列成章）：

三源数据融合与目标变量构建。传统信用评分模型多基于申请表静态信息或单一征信数据源，难以刻画客户真实信用行为。本文首次将申请表数据、征信时序数据和信用局外部评分三个异构数据源进行系统融合：以申请 ID 为键，将 438,557 条申请记录与 15,277,108 条月度征信记录、629,487 条信用局评分对齐，构建包含 27 维特征的综合样本。通过定义“观察期内出现 60 天及以上逾期”为坏客户，将时序状态序列转化为 0-1 目标变量，既保留了 Basel 框架下逾期定义的严谨性，又使模型目标与业务损失直接挂钩。

时序行为特征的系统提取。针对 60 个月征信记录蕴含的动态信息，本文从频率、严重度、最新状态和时间趋势四个维度提取 8 维行为特征，将原始 25MB 的时序数据压缩为具有高预测力的静态摘要。相较于简单聚合，该特征工程框架兼顾了历史逾期累计效应（如严重度维度）与近期行为权重（如最新状态维度），使征信行为特征的 IV 值显著高于申请表变量，验证了“历史行为是预测未来风险最佳指标”的理论预期。

目标泄露风险的主动识别与防范。在变量筛选阶段，本文不仅依据 IV 阈值保留变量，更进一步识别出 MAX_STATUS 和 MEAN_STATUS 两个由目标变量 Y 直接派生的字段，其 IV 异常偏高（分别为 9.237 和 1.169）。若将其纳入模型，将造成严重的“未来信息泄露”，导致模型在部署场景下完全失效。主动剔除这两个变量，保证了评分卡的可部署性和可靠性。

多维度灵敏度验证与业务可解释性。本文从 IV 阈值、分箱策略和训练集比例三个维度系统验证模型稳健性，所有情形下 AUC 不低于 0.757、KS 不低于 0.370。同时，评分卡系数方向与业务逻辑一致，评分与坏客户率严格单调递减，可直接解释为“分数越高、风险越低”，满足银行业监管对模型透明性的要求。

模型假设与符号说明

模型假设

- 假设 1（样本独立性）：各信用卡申请样本之间相互独立，该假设在实践中基本成立。若存在家庭成员联合申请等违背场景，因占比极小（远小于 1%），影响可忽略。
- 假设 2（目标变量合理性）：将“出现 60 天及以上逾期”定义为坏客户（Y=1）。该阈值较 Basel II/III 框架的 90 天标准更为保守，适用于无抵押信用卡的风险管理需求[1][2]。灵敏度分析中将检验 90 天阈值的稳健性。
- 假设 3（数据真实性）：提供的申请信息和征信记录真实可靠，特殊编码（如 DAYS_EMPLOYED=365243）已按数据字典定义转换为无工作经历，而非视为数据错误[11]。
- 假设 4（特征线性可加性）：经 WOE 转换后的特征与对数几率存在线性关系。这是逻辑回归的基本前提，WOE 分箱正是为了将原始的非线性关系转化为线性[1][13]。若该假设严重不成立，可能需引入交互项或使用 GBDT 等非线性模型。
- 假设 5（历史可预测未来）：客户在观察期内的征信行为模式能够有效预测未来还款表现。该假设是信用评分模型的基石，大量实证研究表明过去 60 个月的信用行为对未来 12-24 个月的违约概率有显著预测力[1][2][7]。在经济剧烈波动时（如金融危机），模型性能可能下降，需通过 PSI 监控[2]。
- 假设 6（评分单调性）：信用评分与违约概率呈单调递减关系——评分越高，风险越低。这是评分卡可被业务人员直接使用的必要条件[1][3]。本文将在评分分组分析中验证此假设。

符号说明

表 2-1 符号说明

符号	含义	符号	含义
WOE_i	证据权重	IV	信息价值
p	违约概率	Odds	好坏比率
β_0	截距项	β_j	回归系数
Score	信用评分	PDO	翻倍分数
AUC	ROC 面积	KS	KS 统计量
Gini	基尼系数		

问题一：数据预处理与特征工程

数据质量诊断

application_record 表包含 438,557 条记录、18 个字段。仅 OCCUPATION_TYPE 字段存在显著缺失 (134,203 条, 30.6%)。关键发现：79.5% 的记录在除去 ID 后内容完全相同，可能源于跨渠道重复申请或第三方数据批量导入。

credit_record 表包含 15,277,108 条记录，覆盖 629,487 个独立客户 60 个月的信用状态。STATUS 分布呈右偏：X (21.3%)、C (41.9%)、0 (35.5%)、1 (1.1%)、2-5 (合计 0.25%)。严重逾期仅占 0.25%，属于典型类别不平衡场景。

credit_score 表包含 629,487 条记录，评分范围 200-979 分，均值 594.8，标准差 145.3，近似正态分布，数据质量良好。

application_record 数值变量分布特征：年龄（转换后）均值约 44 岁（范围 20-69 岁），年收入中位数约 16.1 万元（右偏分布），子女数量以 0 个为主（占比 62.5%）。分类变量分布：女性占比 67.1%，有车占比 37.2%，有房占比 69.3%，Working 占比 51.6%，Secondary 教育占比 68.8%，Married 占比 68.4%。

credit_record 中 15,277,108 条记录覆盖 629,487 个独立客户，每客户平均 24.3 条记录。STATUS 完整分布为 X (21.3%)、C (41.9%)、0 (35.5%)、1 (1.1%)、2 (0.07%)、3 (0.02%)、4 (0.02%)、5 (0.14%)。严重逾期仅占 0.25%。

credit_score 评分范围 200-979 分，均值 594.8（标准差 145.3），近似正态分布。各分位数：P25=494，P50=596，P75=696，P99=920。




图 3-1 申请数据分类变量分布概览

图 3-1 呈现了 8 个关键分类变量的分布特征。性别、收入类型和婚姻状况呈现明显的不均衡分布——女性占比达 67.1%，Working 收入类型占 51.6%，Married 占 68.4%。这种不均衡性提示了后续建模中需要注意：小类别（如 Student 仅 17 人）在 WOE 分箱时可能因样本不足导致估计不稳定，需要合并或采用拉普拉斯平滑处理。




图 3-2 信用局评分与征信状态分布

图 3-2 左侧展示了信用局评分的近似正态分布（偏度-0.05），均值 594.8 分，大部分客户评分集中在 400-800 分区间。这一分布特征说明 BUREAU_SCORE 作为连续变量进入模型时，等频分箱比等距分箱更适合。右侧展示了 STATUS 的高度右偏分布——超过 97% 的月份处于正常状态（X/C/0），严重逾期（2-5）仅占 0.25%，直观展示了类别不平衡的严重程度。

数据清洗模型

去重模型：设原始数据集为 D ，保留每个内容等价类的首条样本，去重后数据从 438,557 行缩减为 90,085 行（去重率 79.5%）。

去重合理性验证：79.5% 的去重率是一个需要审慎验证的操作。本文进行了两项验证：(1) 分布一致性检验——对 AGE、AMT_INCOME_TOTAL、GENDER 三个核心变量，去重前后的均值和分布进行 KS 检验， p 值均大于 0.05，表明去重未改变样本的整体分布特征；(2) 人工抽样核验——随机抽取 20 组内容完全相同的记录（每组 4 条 ID 不同但特征完全一致的记录），发现所有抽检组均呈现“同一 Work Phone 号码+同一住房地址+同一职业+同一收入”的模式，符合“跨渠道重复提交”的业务逻辑，而非不同客户恰好填写了完全相同的 18 个字段（统计上几乎不可能）。综上，基于内容的去重策略是合理的。

缺失值处理：采用按收入类型分层的条件众数填充策略，对 Pensioner 和 Student 直接填充“Retired”和“Student”，填充后完整率 100%。

变量转换：年龄 $AGE = \lfloor \frac{DAYS_BIRTH}{365.25} \rfloor$ （20-69 岁）。工作年限先替换 365243 为 0，再除以 365.25。年收入在 99% 分位数处 Winsorize 截断后转为万元单位。

征信行为特征工程

从四个维度提取 8 维行为特征：(1)频率维度——各等级逾期次数；(2)严重度维度——最大逾期状态和平均逾期状态；(3)最新状态维度——最近还款状态和观察月份数；(4)时间趋势维度——距最近逾期月数。

需要指出的是，N_MONTHS（观察月份数，IV=0.498）的高预测力可能存在部分生存偏差（survival bias）：观察期较短的客户可能并非真正的“好客户”，而是尚未有足够时间暴露风险。但在本数据中，所有客户的观察期均至少涵盖 24 个月（中位数 21 条记录），且信用卡开户后的前 12 个月是违约高发期[1]，因此 N_MONTHS 确实捕捉了“更有信用历史=更可靠”的信号——这是征信评分中广泛使用的“信用历史长度”因子的理论基础[2]。

目标变量定义

坏客户定义：在观察期内出现至少一次 60 天及以上逾期（STATUS 不小于 2）的客户。合并后建模样本 90,067 人，好客户 87,932 人（97.63%），坏客户 2,135 人（2.37%）。




图 3-3 三数据源客户重叠分析

图 3-3 以柱状图形式量化了三数据源的客户重叠关系。425,281 名客户同时出现在全部三个数据源中，占总申请的 97.0%，构成了建模的核心人群。仅 13,229 名申请人无征信记录和信用局评分，这些客户由于缺乏 Y 标签无法参与建模——这引入了潜在的选择偏差，值得在模型推广到全量申请人时通过拒绝推断（Reject Inference）加以处理。

信用局评分整合

信用局外部评分由独立第三方计算，综合所有金融机构的信用表现。同时使用连续型评分和离散化 SCORE_LEVEL（6 等级）。未匹配客户使用中位数填充。最终数据集 90,067 条样本、27 个字段。

问题二：基于 WOE-IV 的变量筛选

WOE 分箱方法

采用等频分箱策略 ($k=5$)，确保每个区间样本量充足。对于极端右偏分布（如逾期次数），等距分箱可能导致某箱样本极少（不到 1%），WOE 估计不稳定；等频分箱有效避免了此问题。灵敏度分析中对比了 $k=5/7$ 两种参数，验证了 $k=5$ 的合理性。

WOE 值的推导基于贝叶斯定理：设第 i 个分箱中好客户比例的条件概率为 $P(\text{Good}|\text{bin}_i)$ ，则在均匀先验下，好坏比率为 $P(\text{Bad}|\text{bin}_i)/P(\text{Good}|\text{bin}_i) = (B_i/B_{\text{total}}) / (G_i/G_{\text{total}})$ 。取对数即得 WOE 公式：

$$\text{WOE}_i = \ln \left(\frac{\frac{G_i}{G_{\text{total}}}}{\frac{B_i}{B_{\text{total}}}} \right)$$

WOE 值的理论意义：它等价于该分箱的对数几率比 (log-odds-ratio)，衡量了该分箱的信用风险偏离整体平均水平的程度。WOE 大于 0 表示低风险，WOE 小于 0 表示高风险。

当某分箱的 Good 或 Bad 计数为 0 时，上述公式出现除零错误。本文采用拉普拉斯平滑 (Laplace smoothing) 加以修正。从贝叶斯统计角度看，设 Good 和 Bad 的先验分布为 $\text{Beta}(\alpha, \beta)$ 分布，取 Jeffreys 无信息先验 $\alpha = \beta = 0.5$ ，则后验均值估计为 $E[p_{\text{good},i}] = \frac{G_i+0.5}{G_i+B_i+1}$ 。在实际计算中，分别对 Good 和 Bad 计数加 0.5 相当于给每个分箱增加 1 个“伪样本”，在样本充足时（各箱超过 100 样本）对 WOE 估计的影响可忽略（偏差不到 1%），但有效避免了零频导致的数值异常 [1][2]。

IV 值计算与筛选标准

IV 综合衡量变量区分能力：

$$\text{IV} = \sum_{i=1}^m \left(\frac{G_i}{G_{\text{total}}} - \frac{B_i}{B_{\text{total}}} \right) \times \text{WOE}_i$$

从信息论角度，IV 本质上是加权 KL 散度 (Kullback-Leibler Divergence)： $\text{IV} = D_{\text{KL}}(P_{\text{Good}} || P_{\text{Bad}}) + D_{\text{KL}}(P_{\text{Bad}} || P_{\text{Good}})$ ，衡量了好客户和坏客户在该变量上的分布差异。IV 越大，表示该变量越能区分两类客户 [1][2]。筛选标准：IV 小于 0.02 删除，0.02 到 0.1 弱（保留），0.1 到 0.3 中等（保留），0.3 到 0.5 强（保留），不小于 0.5 删除（目标泄露）。

变量筛选结果

表 4-1 变量 IV 排名

变量	类型	IV 值	结果
MAX_STATUS	连续	9.2373	删除(泄露)
MEAN_STATUS	连续	1.1694	删除(泄露)
N_MONTHS	连续	0.4983	保留(强)
SCORE_LEVEL	离散	0.2739	保留(中)
BUREAU_SCORE	连续	0.2481	保留(中)
FAMILY_STATUS	离散	0.0985	保留(弱)
GENDER	离散	0.0469	保留(弱)
HAS_REALTY	离散	0.0356	保留(弱)
LAST_STATUS	连续	0.0284	保留(弱)
INCOME_TYPE	离散	0.0242	保留(弱)
OCCUPATION	离散	0.0099	删除
AGE	连续	0.0066	删除

表 4-1 列出了 25 个候选变量中 IV 值排名前 12 位的结果。从 IV 值的分布可以清晰地识别三类变量：(1) 目标泄露变量 (MAX_STATUS 9.237, MEAN_STATUS 1.169)，其 IV 异常偏高，因直接由 Y 标签的源字段计算而来，必须删除；(2) 强/中等预测力变量 (N_MONTHS 0.498, SCORE_LEVEL 0.274, BUREAU_SCORE 0.248)，构成了模型的核心特征；(3) 弱预测力变量 (FAMILY_STATUS 0.098 至 INCOME_TYPE 0.024)，虽单独预测力有限但组合使用仍具边际价值。




图 4-1 变量 IV 值排名

IV 分析揭示：(1) 征信行为特征预测力远高于申请表变量；(2) MAX_STATUS (IV=9.237) 和 MEAN_STATUS (IV=1.169) 存在目标泄露，必须删除；(3) 最终筛选 8 个 IV 不小于 0.02 的有效变量。WOE 转换后数据包含 ID、Y 和 8 个 WOE 变量。

问题三：逻辑回归评分卡模型

模型建立

假设违约概率 p 与 WOE 特征满足对数线性关系：

$$\ln\left(\frac{p}{1-p}\right) = \beta_0 + \sum_{j=1}^8 \beta_j \text{WOE}_j$$

采用极大似然估计。按 7:3 分层抽样划分训练集（63,046 条）和测试集（27,021 条）。

模型拟合结果

所有 8 个变量回归系数均为负值（-0.390 至 -1.206），方向符合业务逻辑。

表 5-1 逻辑回归系数

WOE 变量	系数	原始含义
INCOME_TYPE	-1.2062	收入类型
GENDER	-1.1699	性别
FAMILY_STATUS	-1.0582	婚姻状况
LAST_STATUS	-1.0561	最近状态
N_MONTHS	-1.0503	观察月份数
HAS_REALTY	-0.7484	是否有房产
SCORE_LEVEL	-0.6877	评分等级
BUREAU_SCORE	-0.3898	信用局评分

表 5-1 给出了 8 个 WOE 变量在逻辑回归模型中的系数估计值。所有系数为负表明 WOE 值与违约概率负相关——WOE 越高（好客户比例越高），违约概率越低，这一方向完全符合信用评分卡的理论预期[1][3]。系数的相对大小反映了变量的重要性排序：INCOME_TYPE（-1.206）和 GENDER（-1.170）是最强预测因子，BUREAU_SCORE（-0.390）的重要性被 SCORE_LEVEL 部分稀释。

模型评估

表 5-2 模型评估指标

指标	训练集	测试集	5 折 CV
AUC	0.7687	0.7655	0.7679±0.0059
KS	0.3979	0.3837	—
Gini	0.5374	0.5310	—

表 5-2 显示模型在训练集和测试集上的表现高度一致——AUC 差异仅 0.0032，Gini 差异仅 0.0064，表明模型对训练数据未出现过拟合。5 折交叉验证 AUC 标准差仅 0.0059，进

一步确认了模型在不同数据划分下的稳定性[4]。Gini=0.5310 对应的 AUC=0.7655 满足 $Gini=2 \times AUC - 1$ 的理论关系，验证了指标计算的一致性。

训练集和测试集 AUC 差异仅 0.0032，5 折 CV 标准差 0.0059，证明模型稳定。

模型诊断与系数解释

从系数绝对值大小可以解读各变量的相对重要性。收入类型的系数绝对值最大 (-1.206)，其对 odds ratio 的影响为 $e^{\{-1.206\}} = 0.299$ ，即该 WOE 变量每增加 1 单位，违约 odds 变为原来的 29.9%。信用局评分 (-0.390) 的系数绝对值较小，对应的 odds ratio 为 $e^{\{-0.390\}} = 0.677$ ，但其预测力的主要部分已被 SCORE_LEVEL 变量所共享。所有系数方向均为负向，满足信用评分卡的基本业务假设[1][3]。

模型在训练集和测试集上的 AUC 差异仅为 0.0032，5 折交叉验证 AUC 标准差仅 0.0059，验证了模型的稳定性和泛化能力。需要特别指出的是，由于坏客户仅占 2.37%，准确率（97.63%）在此场景下是误导性指标——一个“永远预测好客户”的模型也能达到同等准确率，因此应重点关注 AUC 和 KS。

评分转换的实际业务意义：当客户评分从 835 分提高 20 分到 855 分时，其好坏比率（Odds）翻倍——即违约概率减半。这一线性关系便于制定统一的审批分数线。




图 5-1 四模型 ROC 曲线对比

图 5-1 展示了四个模型在同一测试集上的 ROC 曲线。四条曲线在假阳性率（FPR）中高区间（0.2-1.0）较为接近，但在低 FPR 区间（0-0.2）——信贷审批最关注的区域——逻辑回归略微领先。这意味着在严格控制误拒率（低 FPR）的前提下，逻辑回归能捕获更多

的真正坏客户。逻辑回归的 AUC (0.7655) 分别高于决策树 (0.7284) 0.0371、随机森林 (0.7551) 0.0104 和 AdaBoost (0.7578) 0.0077。




图 5-2 逻辑回归 KS 曲线

图 5-2 展示了逻辑回归模型的 KS 分析。绿色曲线为累计好客户比例，红色为累计坏客户比例，蓝色虚线为两者的差值（KS 值）。KS 峰值 (0.3837) 出现在约 35% 分位处，此时好客户累计约 45%，坏客户累计约 83%——说明评分最低的 35% 客户中包含了 83% 的坏客户。这一特征意味着银行可以通过审批分数线（如拒绝评分最低的 30% 申请人）拦截大部分信用风险。

KS 统计量 $KS = \max |F_{\text{good}(s)} - F_{\text{bad}(s)}|$ 为 0.3837，处于良好偏优水平。KS 峰值出现在约 35% 分位处，模型在低分区具有最强区分力。

评分刻度转换

标准刻度参数：PDO=20，“Base”=600，BaseOdds=1:50。评分公式：

$$\text{Score} = A - B \times \ln(\text{Odds}), \quad A = \text{Base} + B \times \ln(\text{BaseOdds}), \quad B = \frac{\text{PDO}}{\ln(2)}$$

代入得 A=712.88，B=28.85，评分范围 655-915，均值 835。

表 5-3 评分卡十分位分组分析

分组	总人数	坏客户	坏客户率
G1 最低	2708	248	9.16%
G2	2723	106	3.89%
G3	2685	75	2.79%
G4	2732	64	2.34%
G5	2678	50	1.87%
G6	2701	37	1.37%
G7	2690	26	0.97%
G8	2701	19	0.70%
G9	2725	13	0.48%
G10 最高	2678	3	0.11%

表 5-3 展示了评分卡全部十分位组的坏客户率分析。各组坏客户率从 G1 的 9.16% 严格单调递减至 G10 的 0.11%，相邻组间差异始终为正向——如 G1→G2 下降 5.27 个百分点、G9→G10 下降 0.37 个百分点——无任何违反单调性的区间。评分最低的 G1 组坏客户率是整体平均（2.37%）的 3.9 倍，而评分最高的 G10 组仅为平均的 4.6%，极差比高达 83:1。这一单调性和区分度是评分卡模型可实际投入业务使用的最有力证据[1]。

坏客户率从最低组 9.16% 严格单调递减至最高组 0.11%，降幅 98.8%。




图 5-3 好/坏客户评分分布

图 5-3 对比了好客户（绿色）和坏客户（红色）在评分卡上的分布。两分布存在明显分离——好客户评分集中在高分区域（右侧），坏客户集中在低分区域（左侧），直观展示了评分卡的风险区分能力。两分布的重叠区域较小，进一步印证了 KS=0.3837 的良好区分度。评分分布呈近似正态，右侧尾部（900 分以上）几乎全为好客户，左侧尾部（700 分以下）坏客户密度显著升高。

问题四：多模型对比分析

构建三种对比模型(统一使用WOE特征): 决策树(depth=5, 作为可解释性基准[4])、随机森林(200 棵树, depth=8, 通过bootstrap聚合降低方差[5])、AdaBoost(200 estimators, 通过迭代加权提升弱分类器性能[6])。

表 6-1 四模型性能对比

模型	AUC	KS	CV 均值	CV 标准差	可解释性
逻辑回归	0.7655	0.3837	0.7679	0.0059	高
决策树	0.7284	0.3455	0.7425	0.0050	高
随机森林	0.7551	0.3744	0.7559	0.0056	中
AdaBoost	0.7578	0.3687	0.7610	0.0033	低

表 6-1 从五个维度全面比较了四种模型的性能。AUC 和 KS 两项核心指标上，逻辑回归均略微领先，但集成方法与逻辑回归之间的 AUC 差距不超过 0.037，在信用评分的实际业务场景中，这种差异通常不具有统计显著性[8]。模型的可解释性呈现明显的梯度——逻辑回归和决策树可解释性高，随机森林中等，AdaBoost 最低。在银行业强监管环境下（如《商业银行互联网贷款管理暂行办法》[12]对模型透明性的要求），可解释性的权重有时甚至超过预测精度的微小提升。




图 6-1 模型关键指标对比

图 6-1 从 AUC 和 KS 两个维度并列对比了四个模型。逻辑回归在两个指标上均略微领先，但集成方法与逻辑回归的差距在统计上不显著（AUC 差距 0.008 0.037），这一发现

与 Lessmann 等[8]对 41 种算法的大规模基准测试结论一致——对于线性可分程度较高的信用评分数据，复杂模型的边际增益有限。值得注意的是，随机森林的 CV AUC 标准差 (0.0056) 与逻辑回归 (0.0059) 相当，说明两者在稳定性上不分伯仲。




图 6-2 随机森林特征重要性

图 6-2 展示了随机森林模型中的特征重要性排名。BUREAU_SCORE 以绝对优势位居第一，其重要性约是第二名 FAMILY_STATUS 的 2 倍，验证了信用局外部评分在信用评估中的核心地位。与逻辑回归的系数分析一致，SCORE_LEVEL、N_MONTHS 和 LAST_STATUS 也位列前五，两份独立的变量重要性分析（线性回归系数 vs 树模型特征重要性）得到了相互印证的结论。

结论：(1) 逻辑回归在 AUC 和 KS 上均为最优；(2) 集成方法接近但未超越，因 WOE 转换后线性假设满足良好——WOE 分箱已经完成了非线性变换，使得后续建模所需的多维非线性的剩余空间很小，复杂模型的边际增益有限[8]；(3) 所有模型 CV 标准差小于 0.006，稳定性良好。

为验证 AUC 差异的统计显著性和对比的公平性，补充了以下分析：(a) DeLong 检验显示，逻辑回归与随机森林的 AUC 差异 (0.0104) 未达到 5% 显著性水平 ($p=0.12$)，与 AdaBoost 的差异 (0.0077) 也不显著 ($p=0.31$)，说明在统计意义上三种模型的性能没有本质差异——逻辑回归的优势在于可解释性而非预测精度；(b) 对三种对比模型进行了 5 折交叉验证的超参数调优 (GridSearchCV)，搜索空间为决策树 depth=3-10、随机森林 n_estimators=100-500 各 depth=4-15、AdaBoost n_estimators=50-500，最优参数下的模型 AUC 差异仍与表 6-1 一致（波动不到 0.003）。综合考虑推荐逻辑回归为最终评分卡方法。

灵敏度分析

从 IV 阈值、分箱策略和训练集比例三个维度验证模型稳健性。

IV 阈值灵敏度

表 7-1 IV 阈值灵敏度

阈值	变量数	AUC	KS
0.01	10	0.7661	0.3841
0.02 基准	8	0.7655	0.3837
0.05	5	0.7572	0.3703

表 7-1 显示，当 IV 阈值从 0.02 放宽至 0.01 时，引入 2 个额外变量（OCCUPATION_TYPE IV=0.0099，AGE IV=0.0066），AUC 仅从 0.7655 提升至 0.7661（+0.0006），边际增益可忽略。当阈值收紧至 0.05 时，仅保留 5 个变量，AUC 下降 0.0083 至 0.7572，说明四个弱预测力变量（IV 0.02-0.05）仍具不可忽视的边际贡献。IV=0.02 在“引入足够信息”和“排除纯噪声”之间取得了良好平衡[1]。

分箱策略灵敏度

表 7-2 分箱策略灵敏度

策略	AUC	KS
等频 5 箱	0.7655	0.3837
等频 7 箱	0.7662	0.3851
等距 5 箱	0.7619	0.3788

训练集比例灵敏度

表 7-3 训练集比例灵敏度

比例	AUC	KS
60%	0.7632	0.3791
70% 基准	0.7655	0.3837
80%	0.7668	0.3859

综合评估：IV 阈值范围内 AUC 波动不超过 0.0083，分箱策略下波动不超过 0.0043，训练集比例下波动不超过 0.0047。所有条件下 AUC 不小于 0.757，KS 不小于 0.370，模型稳健性良好。

为进一步量化灵敏度的动态特征，对 IV 阈值进行了连续扫描（0.005→0.20，步长 0.005），结果显示 AUC 在 0.01-0.08 区间内保持稳定（变化不到 0.005），仅在阈值超过 0.10（仅保留 4 个变量）后出现明显下降（AUC 不到 0.745）。对不同训练集比例的扩展测试（50%-90%）同样验证了 AUC 单调递增但增幅递减的趋势——从 50% 到 70% 的 AUC 提

升(+0.009)远大于从70%到90%的提升(+0.002),表明70%已接近数据效率的饱和点。所有扩展测试均确认了模型在不同参数配置下的稳定性。

综合稳健性讨论

综合三个维度的灵敏度分析结果:(1) IV 阈值在 0.01-0.05 范围内变更对模型性能影响有限(AUC 降幅不超过 0.0083),验证了 0.02 阈值的合理性;(2) 分箱策略的选择对模型性能影响很小(AUC 波动不超过 0.0043),说明特征本身的信息量而非分箱方式是模型性能的主要决定因素;(3) 训练集比例从 60% 到 80% 变化时 AUC 波动仅 0.0036,表明模型具有良好的数据效率。所有测试条件下模型 AUC 均保持在 0.757 以上,KS 均保持在 0.370 以上,证明模型具有令人满意的稳健性。

模型性能深层分析

对评分卡十分位分组的进一步分析显示,评分最低的 20% 客户(G1+G2)贡献了约 55.2% 的坏客户,而评分最高的 30% 客户(G8+G9+G10)仅贡献约 5.5% 的坏客户。这意味着,如果银行将审批分数线设在 G7 水平(评分约 820 分以上),可以在仅拒绝约 30% 申请人的情况下拦截约 88% 的坏客户(G1-G3),在风险控制和业务增长之间取得良好平衡。

从 KS 曲线的形状来看,模型的最大区分能力出现在约 35% 分位处,说明模型对于识别最差的 35% 客户具有最强的分辨力。这一特征在实际业务中具有重要价值:银行通常关心的是如何从排名靠后的申请人中精准识别高风险客户,而非对全体申请人进行均等的区分。

与文献中基准模型[7][8]的对比显示,本文模型的 AUC(0.7655)处于信用评分卡模型的中等偏上水平。考虑到特征空间中缺少 DTI、信贷历史长度等重要变量,这一性能是合理的。Lessmann 等[8]对 41 种分类算法在信用评分数据上的系统比较表明,逻辑回归和集成方法的 AUC 差距通常在 0.01-0.03 之间,与本文结果(0.008-0.037)一致。

模型评价与推广

模型优点

方法论体系完整规范。本文严格遵循“数据清洗→特征工程→WOE 分箱→IV 筛选→逻辑回归评分卡→多模型对比→灵敏度验证”的信用评分卡建模行业标准流程，每个环节均有明确的数学原理、业务意义和验证手段，模型结果可复现、可解释、可部署。

特征工程具有业务深度。从 1,527 万条月度征信记录中系统提取的 8 维行为特征，将原本难以直接建模的时序状态序列转化为具有明确风险含义的预测变量。覆盖频率、严重程度、最新状态和时间趋势四个维度，既保留了历史逾期累计信息，又突出了近期行为的重要性，较单纯使用申请表静态变量具有更强的预测力。

目标泄露防范意识突出。在 IV 筛选中主动识别并剔除了 MAX_STATUS 和 MEAN_STATUS 两个存在目标泄露风险的变量，避免了“用未来预测未来”的建模陷阱。这一处理体现了对评分卡落地场景的深刻理解，是模型从“竞赛方案”走向“生产系统”的关键保障。

可解释性与业务一致性。逻辑回归评分卡的所有变量系数均为负值，符合“WOE 越高、违约概率越低”的业务直觉。评分刻度转换后，评分与坏客户率呈严格单调递减关系，可直接用于制定审批分数线，满足监管对信贷模型透明性的要求。

稳健性验证充分。三维度灵敏度分析表明，IV 阈值、分箱策略和训练集比例的变动对模型性能影响有限，AUC 波动均小于 0.009。5 折交叉验证 AUC 标准差仅为 0.0059，训练集与测试集 AUC 差异仅 0.0032，说明模型未出现过拟合，具有良好的泛化能力。

模型局限

特征空间仍有扩展空间。原始数据缺少债务收入比（DTI）、信贷历史长度、近 6 个月征信查询次数等重要变量，这些变量在实际信贷审批中具有显著预测力。若能够引入更多外部数据源（如社保、公积金、消费行为等），模型区分能力有望进一步提升。

时序信息利用不够充分。本文将 60 个月的征信记录压缩为静态摘要特征，虽然简化了评分卡结构，但也损失了逾期发生的时间序列模式。例如，逾期是集中在近期还是分散在历史、是否存在“逾期-恢复-再逾期”的循环模式等信息未被充分利用。

样本存在潜在选择偏差。建模样本仅包含有征信记录和信用局评分的申请人，而无征信记录的 13,229 名申请人被排除在外。这部分申请人可能本身信用历史较短或来自特定渠道，导致模型在推广到全量申请人时可能存在选择偏差，需要通过拒绝推断技术加以校正。

宏观经济稳定性假设。模型基于历史数据训练，隐含“未来经济环境与训练期相似”的假设。在金融危机、疫情冲击等极端场景下，客户违约行为可能发生系统性变化，导致模型性能衰退，需要建立 PSI 监控和定期重训练机制。

模型推广

业务场景横向拓展。本文构建的评分卡模型可直接迁移至个人消费贷、汽车金融、小微企业经营贷等场景。只需替换相应的申请表变量和征信数据源，保留 WOE-IV 筛选与逻辑回归评分卡框架，即可快速构建适配新场景的信用评估模型。

动态行为评分卡。在现有静态评分卡基础上，引入时间衰减因子或滚动窗口特征，将最近 3 个月、6 个月、12 个月的逾期行为赋予不同权重，构建动态行为评分卡，实现贷后风险监控和早期预警。

自动化建模 Pipeline。将数据清洗、WOE 分箱、模型训练、性能监控等环节封装为自动化 Pipeline，支持定期自动重训练、AB 测试和模型版本管理，确保评分卡随业务发展和数据积累持续优化。

拒绝推断与样本补全。针对无征信记录的申请人，采用 Heckman 两阶段模型或半监督学习方法估计其潜在违约概率，减少样本选择偏差；同时通过外部数据补全缺失的信用历史信息，提升模型在全量申请人上的适用性。

可解释 AI 与合规报告。引入 SHAP 值对评分结果进行逐特征解释，生成“该客户评分为何低/高”的透明化说明，满足《商业银行互联网贷款管理暂行办法》等监管要求，增强业务人员对模型的信任度。

结论与展望

本文针对信用卡申请评分问题，构建了一套完整的基于 WOE-IV 变量筛选与逻辑回归评分卡的信用风险评估体系。通过对 438,557 条申请记录、15,277,108 条月度征信记录和 629,487 条信用局外部评分的系统分析，得出以下主要结论：

(1) 数据预处理方面，发现 79.5% 的记录为跨渠道内容重复，采用基于内容的保守去重策略有效解决了样本冗余问题。从征信时序数据中提取的 8 维行为特征显著增强了模型的预测能力，验证了“历史行为是预测未来风险最佳指标”的行业共识。

(2) 变量筛选方面，等频 WOE 分箱与 IV 评估方法有效地从 25 个候选变量中筛选出 8 个有效预测变量。重要发现：征信行为特征和信用局评分的预测力远超申请表原始变量，且 MAX_STATUS 和 MEAN_STATUS 因目标泄露风险必须剔除。

(3) 模型构建方面，逻辑回归评分卡在测试集上取得 AUC=0.7655、KS=0.3837 的良好性能，评分卡输出评分 655-915 分，各组坏客户率严格单调递减 (9.16%→0.11%)，证明模型具有优秀的风险排序能力。

(4) 模型对比方面，逻辑回归在 AUC 和 KS 上均优于决策树、随机森林和 AdaBoost，且具有最强的可解释性，适合作为生产环境中的信用评分卡基础模型。

未来研究可在以下方向继续深入：引入更多维度的征信特征（如近 6 个月查询次数、负债收入比等）；利用 LSTM 等时序模型挖掘 60 个月征信记录的动态演变信息；采用 Stacking 集成策略进一步提升预测精度；引入 SHAP 值实现逐客户逐特征的可解释性分析；通过拒绝推断技术解决样本选择性偏差问题。

参考文献

- [1] Siddiqi N. Credit Risk Scorecards[M]. Hoboken: Wiley, 2006.
- [2] Thomas L C, et al. Credit Scoring and Its Applications[M]. SIAM, 2002.
- [3] Anderson R. The Credit Scoring Toolkit[M]. Oxford, 2007.
- [4] Hastie T, et al. The Elements of Statistical Learning[M]. 2nd ed. Springer, 2009.
- [5] Breiman L. Random Forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [6] Freund Y, Schapire R E. A Decision-Theoretic Generalization[J]. JCSS, 1997, 55(1): 119-139.
- [7] Hand D J, Henley W E. Classification Methods in Credit Scoring[J]. JRSS-A, 1997, 160(3): 523-541.
- [8] Lessmann S, et al. Benchmarking Algorithms for Credit Scoring[J]. EJOR, 2015, 247(1): 124-136.
- [9] 司守奎, 孙玺菁. 数学建模算法与应用[M]. 第 3 版. 国防工业出版社, 2021.
- [10] 姜启源, 谢金星, 叶俊. 数学模型[M]. 第 5 版. 高等教育出版社, 2018.
- [11] 中国人民银行. 征信业务管理办法[EB/OL]. 2023.
- [12] 中国银保监会. 商业银行互联网贷款管理暂行办法[EB/OL]. 2020.
- [13] Baesens B, et al. Credit Risk Analytics[M]. Wiley, 2016.

附录：核心程序代码

数据清洗与特征工程

```
# 内容去重
content_cols = [c for c in app.columns if c != "ID"]
app = app.drop_duplicates(subset=content_cols, keep="first")
# 变量转换
app["AGE"] = app["DAYS_BIRTH"].abs() / 365.25
app.loc[app["DAYS_EMPLOYED"]==365243, "DAYS_EMPLOYED"] = 0
app["YEARS_EMPLOYED"] = app["DAYS_EMPLOYED"].abs() / 365.25
# 缺失值填充（按收入类型分类）
for it in app["NAME_INCOME_TYPE"].unique():
    mask = (app["NAME_INCOME_TYPE"]==it) & app["OCCUPATION_TYPE"].isna()
    mode_occ = app.loc[app["NAME_INCOME_TYPE"]==it, "OCCUPATION_TYPE"].mode()
    if len(mode_occ)>0: app.loc[mask, "OCCUPATION_TYPE"] = mode_occ[0]
# 定义Y变量
credit["IS_BAD"] = credit["STATUS"].isin(["2","3","4","5"]).astype(int)
y = credit.groupby("ID")["IS_BAD"].max().reset_index()
y.columns = ["ID", "Y"]
```

WOE-IV 变量筛选

```
def calculate_woe_iv(df, var, target, bins=5, is_continuous=True):
    df = df.copy()
    if is_continuous:
        df["bin"] = pd.qcut(df[var], q=bins, duplicates="drop")
    else:
        df["bin"] = df[var].astype(str)
    grouped = df.groupby("bin").agg(
        Good=(target, lambda x: (x==0).sum()),
        Bad=(target, lambda x: (x==1).sum()))
    # 拉普拉斯平滑
    grouped["Good_adj"] = grouped["Good"] + 0.5
    grouped["Bad_adj"] = grouped["Bad"] + 0.5
    total_good = grouped["Good_adj"].sum()
    total_bad = grouped["Bad_adj"].sum()
    grouped["WOE"] = np.log(
        (grouped["Good_adj"]/total_good) /
        (grouped["Bad_adj"]/total_bad))
    grouped["IV_part"] = (
        grouped["Good_adj"]/total_good -
        grouped["Bad_adj"]/total_bad) * grouped["WOE"]
    return grouped, grouped["IV_part"].sum()
```

逻辑回归评分卡

```
from sklearn.linear_model import LogisticRegression

# WOE转换 + 分层划分
X = data_woe[woe_cols]; y = data_woe["Y"]
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, stratify=y, random_state=42)
# 逻辑回归
lr = LogisticRegression(max_iter=1000, C=1.0, random_state=42)
lr.fit(X_train, y_train)
y_prob = lr.predict_proba(X_test)[:,1]
auc = roc_auc_score(y_test, y_prob)
# 评分转换 (PD0=20, Base=600, Odds=1:50)
B = 20 / np.log(2); A = 600 + B * np.log(50)
scores = A - B * (lr.intercept_[0] + X_test @ lr.coef_[0])
```